BÁO CÁO TUẦN 5 + 6

1. Pipeline lập chỉ mục (Indexing)

1.1 Ingestion + Normalization

rag_pipeline.py đọc các định dạng:

- .txt: đọc UTF-8

Sau đó chuẩn hoá:

- Chuẩn hoá xuống dòng (`\r\n` → `\n`)
- Co khoảng trắng/tab
- Giảm nhiều dòng trống liên tiếp

1.2 Chunking ưu tiên cấu trúc văn bản pháp lý:

- Tách theo tiêu đề dòng bắt đầu bằng: Điều, Khoản, Mục.
- Nếu một chunk quá dài: tách tiếp theo số từ để giữ ngữ cảnh vừa đủ.

Tham số build:

- max_words = 600
- overlap_words = 80
- min_words = 40
- batch_size = 16

2. Truy vấn và demo theo điều khoản

1. Đầu vào và đầu ra

- **Đầu vào**:
  - index.faiss: FAISS index lưu embedding chunk.
  - metadata.jsonl: metadata từng chunk (có chunk_id, text, heading, source_path, …).
  - Dataset JSONL: mỗi dòng gồm:
    - query: câu hỏi/truy vấn
    - relevant_chunk_ids: danh sách chunk_id được xem là đúng (ground truth)
- **Đầu ra**:
  - Các chỉ số trung bình theo danh sách : hit@k, precision@k, recall@k, mrr@k, ndcg@k.
  - Tuỳ chọn in chi tiết theo từng query.

2. Các metric áp dụng

2.1. Hit@k (có "đúng" trong top-k hay không)

$$Hit@k = \begin{cases} 1 & \text{nếu có ít nhất 1 kết quả đúng trong top-k} \\ 0 & \text{ngược lại} \end{cases}$$

- **Diễn giải**: đo xem top-k có chứa ít nhất 1 chunk đúng không. Hit@k=1 nghĩa là đã đúng trong k kết quả.
- **Miền giá trị**: 0 hoặc 1.

2.2. Precision@k (độ "sạch" của top-k)

$$P@k = \frac{R_k}{k}$$

- **Diễn giải**: trong k kết quả trả về có bao nhiêu phần trăm là đúng.
- Ví dụ P@5=0.4 nghĩa là 2/5 kết quả là đúng.
- **Miền giá trị**: 0 -> 1.

2.3. Recall@k (độ "bao phủ" ground truth trong top-k)

$$R@k = \frac{R_k}{G}$$

- **Diễn giải**: trong tất cả chunk đúng, top-k đã lấy được bao nhiêu cái.
- Ví dụ R@5=0.5 nghĩa là lấy được 1/2 chunk đúng trong top-5.
- **Miền giá trị**: 0 -> 1.

2.4. MRR@k

$$MRR@k = \begin{cases} \frac{1}{rank^*} & \text{nếu có kết quả đúng trong top-k} \\ 0 & \text{ngược lại} \end{cases}$$

- **Diễn giải**: chỉ quan tâm vị trí của *kết quả đúng đầu tiên* trong top-k.
- Rank 1 → 1.0; Rank 2 → 0.5; Rank 5 → 0.2.
- **Miền giá trị**: 0 -> 1

2.5. DCG@k và nDCG@k (chất lượng xếp hạng, có chiết khấu theo vị trí)

Với rels là chuỗi 0/1 theo thứ hạng:

$$DCG@k = \sum_{i=1}^{k} \frac{rel_i}{\log_2(i+1)}$$

IDCG@k được tính bằng cách xếp toàn bộ kết quả đúng lên đầu:

· ideal_rels = [1] * min(k, G)

$$nDCG@k = \frac{DCG@k}{IDCG@k}$$

- **Diễn giải**:
  - DCG "thưởng" cho việc đưa kết quả đúng lên sớm (vì vị trí càng sâu thì mẫu số $\log_2(i+1)$ càng lớn).
  - nDCG chuẩn hoá về 0..1 bằng cách chia cho trường hợp lý tưởng (IDCG), nên so sánh công bằng hơn giữa các query có số lượng chunk đúng khác nhau.
- **Miền giá trị**: 0 -> 1.

3. Đánh giá chất lượng truy vấn
   - Đối với truy vấn để đánh giá chất lượng ta sẽ thử với từng top-k
   - Dataset được lấy từ file eval_queries.sample.jsonl

```
{"query":"trình tự đầu tư dự án đầu tư ứng dụng công nghệ thông tin","relevant_chunk_
{"query":"xử lý hồ sơ giả mạo đầu tư ra nước ngoài","relevant_chunk_ids":["van-ban_Da
{"query":"tuân thủ khung kiến trúc tổng thể quốc gia số và bảo đảm kết nối liên thông
{"query":"công bố danh mục các phần mềm phổ biến","relevant_chunk_ids":["Ngh_nh_45_20
{"query":"thử nghiệm sản phẩm công nghệ thông tin chưa sẵn có trên thị trường","relev
{"query":"quản lý dự án đầu tư ứng dụng công nghệ thông tin sử dụng vốn ngân sách nhà
{"query":"nhà đầu tư thực hiện hoạt động đầu tư ra nước ngoài theo quy định nào","rel
{"query":"vốn đầu tư ra nước ngoài gồm những nguồn nào","relevant_chunk_ids":["van-ba
{"query":"tiếp nhận hồ sơ và giải quyết thủ tục liên quan đến đầu tư ra nước ngoài","
{"query":"nguyên tắc phát triển đô thị theo nghị định 35/2026","relevant_chunk_ids":[
{"query":"trình tự thủ tục xây dựng kế hoạch phát triển đô thị","relevant_chunk_ids":
```

Dataset

```
PS C:\Users\ADMIN\OneDrive\Documents\TTCS_RAG> python RAG/eval_retrieval.py
--index-dir RAG/output_index --dataset RAG/eval_queries.sample.jsonl --k 1 3
 5 10
Warning: You are sending unauthenticated requests to the HF Hub. Please set
a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100%|
                                                                          | 391/391 [00:00<00:00, 13822
.29it/s]
Batches: 100%|
                                                                          | 1/1 [00:03<00:00,  3
.27s/it]
model_name: BAAI/bge-m3
index_dir: RAG\output_index
dataset: RAG\eval_queries.sample.jsonl
num_queries: 11
index.ntotal: 280 | dim: 1024
ks: [1, 3, 5, 10]
```

Câu lệnh để đánh giá truy vấn

```
=== AVERAGES ===
hit@1: 0.8182
precision@1: 0.8182
recall@1: 0.8182
mrr@1: 0.8182
ndcg@1: 0.8182
hit@3: 0.9091
precision@3: 0.3030
recall@3: 0.9091
mrr@3: 0.8485
ndcg@3: 0.8636
hit@5: 1.0000
precision@5: 0.2000
recall@5: 1.0000
mrr@5: 0.8667
ndcg@5: 0.8988
hit@10: 1.0000
precision@10: 0.1000
recall@10: 1.0000
mrr@10: 0.8667
ndcg@10: 0.8988
```

Kết quả truy vấn

Nhận xét từ kết quả metrics trong ảnh

- Hit@k / Recall@k
  - Hit@1 = 0.8182 và Recall@1 = 0.8182: khoảng 9/11 query lấy đúng ngay top-1.
  - Hit@3 = 0.9091: khoảng 10/11 query có kết quả đúng trong top-3.
  - Hit@5 = 1.0000 (và Recall@5 = 1.0000): 100% query đều có ít nhất 1 chunk đúng trong top-5.

- Precision@k
  - Precision@1 = 0.8182: khớp với Hit@1 (vì k=1).
  - Precision@3 = 0.3030, Precision@5 = 0.2000, Precision@10 = 0.1000: giảm theo k là "đúng bản chất".
  - Lưu ý quan trọng: dataset của bạn đang có xu hướng mỗi query chỉ gán 1 chunk đúng, nên ngay cả khi truy suất "hoàn hảo" thì

- Precision@10 tối đa cũng chỉ là 0.1 (1/10). Vì vậy các giá trị precision thấp ở k lớn không có nghĩa hệ thống tệ, mà là giới hạn của cách gán nhãn + định nghĩa P@k.

- MRR@k
  - MRR@1 = 0.8182: đúng lên rank 1 khoảng 9/11 query.
  - MRR@3 = 0.8485 và MRR@5 = 0.8667: cho thấy các query còn lại thường "đúng nhưng nằm hơi sâu".
  - Với các con số này, có thể suy ra khá sát rằng: 9 query đúng ở rank 1, 1 query đúng khoảng rank 3, và 1 query đúng khoảng rank 5

- nDCG@k
  - nDCG@1 = 0.8182, nDCG@3 = 0.8636, nDCG@5 = 0.8988: ranking nhìn chung đưa đúng lên khá sớm, và càng tăng k thì càng "đỡ miss".
  - nDCG@5 = nDCG@10 = 0.8988: cho thấy với mỗi query, chunk đúng đã nằm trong top-5, nên tăng k lên 10 chỉ thêm nhiễu (precision giảm) chứ không cải thiện ranking của "đúng".

4. Demo theo điều khoản

```
PS C:\Users\ADMIN\OneDrive\Documents\TTCS_RAG> python RAG/retrieval.py -
-index-dir RAG/output_index --heading-contains "Điều 8" --top-k 10
model_name: BAAI/bge-m3
index_dir: RAG\output_index
index.ntotal: 280 | dim: 1024
heading_contains: Điều 8
```

Câu truy vấn theo điều khoản

```
[1] id=16  chunk_id=Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_t_ng_d_ng_c_n
g_ngh_th_ng_tin::16
    heading: Điều 8. Trình
    source: input_docs\Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_t_ng_d_ng_
c_ng_ngh_th_ng_tin.txt
    snippet: Điều 8. Trình tự đầu tư dự án 1. Trình tự đầu tư dự án đầu tư ứng dụng công nghệ thô
ng tin bao gồm các giai đoạn: a) Chuẩn bị đầu tư; b) Thực hiện đầu tư; c) Kết thúc đầu tư. 2. Các
 hoạt động trong giai đoạn thực hiện đầu tư và kết thúc đầu tư có thể thực hiện tuần tự hoặc xen.
..

[2] id=59  chunk_id=Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_t_ng_d_ng_c_n
g_ngh_th_ng_tin::59
    heading: khoản 5 Điều 8 của Nghị định này.
    source: input_docs\Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_t_ng_d_ng_
c_ng_ngh_th_ng_tin.txt
    snippet: khoản 5 Điều 8 của Nghị định này. a) Đơn vị sử dụng ngân sách (sau đây gọi là chủ đầ
u tư) tự thực hiện hoặc thuê tổ chức, cá nhân tổ chức khảo sát (nếu cần thiết) và lập báo cáo ngh
iên cứu khả thi hoặc báo cáo kinh tế - kỹ thuật; trình cấp có thẩm quyền quyết định phê duyệt dự.
..
```

```
[3] id=105  chunk_id=van-ban_Dau-tu_Nghi-dinh-quy-dinh-dau-tu-ra-nuoc-ngoai-453878_as
px::11
ười có thẩm quyền theo quy định của pháp luật xác định có nội dung giả mạo trong hồ s
ơ thực hiện thủ tục đầu tư ra nước ngoài, cơ quan tười có thẩm quyền theo quy định củ
a pháp luật xác định có nội dung giả mạo trong hồ sơ thực hiện thủ tục đầu tư ra nước
 ngoài, cơ quan tười có thẩm quyền theo quy định của pháp luật xác định có nội dung g
iả mạo trong hồ sơ thực hiện thủ tục đười có thẩm quyền theo quy định của pháp luật x
ác định có nội dung giả mạo trong hồ sơ thực hiện thủ tục đầu tư ra nước ngoài, cơ qu
an tiếp nhận hồ sơ thực hiện thủ tục sau: a) Thông báo bằng văn bản cho nhà đầu tư về
...
ười có thẩm quyền theo quy định của pháp luật xác định có nội dung giả mạo trong hồ s
ơ thực hiện thủ tục đầu tư ra nước ngoài, cơ quan tiếp nhận hồ sơ thực hiện thủ tục s
au: a) Thông báo bằng văn bản cho nhà đầu tư về...
ười có thẩm quyền theo quy định của pháp luật xác định có nội dung giả mạo trong hồ s
ơ thực hiện thủ tục đầu tư ra nước ngoài, cơ quan tiếp nhận hồ sơ thực hiện thủ tục s
au: a) Thông báo bằng văn bản cho nhà đầu tư về...
ười có thẩm quyền theo quy định của pháp luật xác định có nội dung giả mạo trong hồ s
ơ thực hiện thủ tục đầu tư ra nười có thẩm quyền theo quy định của pháp luật xác định
 có nội dung giả mạo trong hồ sơ thực hiện thủ tười có thẩm quyền theo quy định của p
háp luật xác định có nội dung giả mạo trong hồ sơ thực hiện thủ tục đười có thẩm quyề
n theo quy định của pháp luật xác định có nội dung giả mạo trong hồ sơ thực hiện thủư
ười có thẩm quyền theo quy định của pháp luật xác định có nội dung giả mạo trong hồ s
ơ thực hiện thủ tục đầu tư ra nước ngoài, cơ quan tiếp nhận hồ sơ thực hiện thủ tục s
au: a) Thông báo bằng văn bản cho nhà đầu tư về...

[4] id=201  chunk_id=van-ban_Xay-dung-Do-thi_Nghi-dinh-35-2026-ND-CP-huong-dan-Nghi-q
uyet-ve-phan-loai-do-thi-286990_aspx::18
    heading: Điều 8. Trình tự, thủ tục xây dựng
    source: input_docs\van-ban_Xay-dung-Do-thi_Nghi-dinh-35-2026-ND-CP-huong-dan-Nghi
-quyet-ve-phan-loai-do-thi-286990_aspx.txt
    snippet: Điều 8. Trình tự, thủ tục xây dựng kế hoạch phát triển đô thị 1. Việc xâ
y dựng kế hoạch phát triển đô thị có thể thực hiện song song với việc xây dựng chương
 trình phát triển đô thị và được phê duyệt sau khi chương trình phát triển đô thị đượ
c phê duyệt. 2. Trình tự, thủ tục x...
```

Kết quả truy vấn

Nhận xét:

- top-k = 10 nhưng có 4 heading khớp được trả về

- Kết quả đang đúng logic của lệnh --heading-contains "Điều 8": nó lọc theo chuỗi “Điều 8” trong trường heading, nên sẽ trả về mọi “Điều 8” ở nhiều văn bản khác nhau, không chỉ 1 văn bản.
    - [1] id=16: heading = "Điều 8. Trình" (đúng “Điều 8” của Nghị định về CNTT)
    - [2] id=59: heading = "khoản 5 Điều 8 của Nghị định này." → có chứa “Điều 8” nhưng không phải tiêu đề “Điều 8.”; đây là đoạn tham chiếu đến Điều 8
    - [3] id=105: heading = "Điều 8. Xử lý hồ sơ giả mạo" → đúng theo filter, nhưng khác văn bản nên cũng là “nhiễu”
    - [4] id=201: heading = "Điều 8. Trình tự, thủ tục xây dựng" (thuộc văn bản đô thị) → cũng đúng theo filter, nhưng khác văn bản.

Một số demo khác:

```
PS C:\Users\ADMIN\OneDrive\Documents\TTCS_RAG> python RAG/retrieval.py --index-dir RAG/
output_index --heading-contains "khoản 5 Điều 3" --top-k 10
model_name: BAAI/bge-m3
index_dir: RAG\output_index
index.ntotal: 280 | dim: 1024
heading_contains: khoản 5 Điều 3
```

```
[1] id=14  chunk_id=Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_t_n
g_d_ng_c_ng_ngh_th_ng_tin::14
    heading: khoản 5 Điều 3 của Nghị định này
    source: input_docs\Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_
t_ng_d_ng_c_ng_ngh_th_ng_tin.txt
    snippet: khoản 5 Điều 3 của Nghị định này (sau đây gọi là dự án mua sắm); c) Dự án
thuê dịch vụ công nghệ thông tin. 2 . Dự án đầu tư ứng dụng công nghệ thông tin sử dụng
 vốn ngân sách nhà nước chi cho đầu tư công thực hiện theo quy định của Luật Đầu tư côn
g và các quy định của Nghị đị...

[2] id=56  chunk_id=Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_t_n
g_d_ng_c_ng_ngh_th_ng_tin::56
    heading: khoản 5 Điều 3 của Nghị định này
    source: input_docs\Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_
t_ng_d_ng_c_ng_ngh_th_ng_tin.txt
    snippet: khoản 5 Điều 3 của Nghị định này ; b) Gia hạn bảo hành theo chính sách của
 nhà sản xuất (bảo hành mở rộng); bảo trì, sửa chữa hệ thống thông tin, phần cứng, phần
 mềm; quản trị, vận hành, thuê quản trị, hỗ trợ kỹ thuật hệ thống thông tin; bảo đảm ho
ạt động thường xuyên cung cấp...

[3] id=57  chunk_id=Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_t_n
g_d_ng_c_ng_ngh_th_ng_tin::57
    heading: khoản 5 Điều 3 của Nghị định này
    source: input_docs\Ngh_nh_45_2026_N_-CP_s_a_i_Ngh_nh_73_2019_N_-CP_quy_nh_qu_n_l_u_
t_ng_d_ng_c_ng_ngh_th_ng_tin.txt
```